

**MODELO DE PREDICCIÓN DEL DESEMPEÑO DE LOS ESTUDIANTES DEL
COLEGIO POLICARPA SALAVARRIETA EN LAS PRUEBAS SABER 11° CON
TÉCNICAS DE MACHINE LEARNING A PARTIR DE SUS HISTÓRICOS DE NOTAS
DESDE 6° A 10°**

RONALDO SIERRA VILORIA

DIRECTOR

**Guillermo Carlos Hernández Hernández
Ingeniero de Sistemas, Msc en Software
Libre**

CODIRECTOR

Sincelejo, Marzo de 2026

1. INFORMACIÓN GENERAL DEL PROYECTO

Título: MODELO DE PREDICCIÓN DEL DESEMPEÑO DE LOS ESTUDIANTES DEL COLEGIO POLICARPA SALAVARRIETA EN LAS PRUEBAS SABER 11° CON TÉCNICAS DE MACHINE LEARNING A PARTIR DE SUS HISTÓRICOS DE NOTAS DESDE 6° A 10°	
Nombre del Estudiante Ronaldo Sierra Vilorio	C.C.: 1193077252
Nombre del Estudiante	C.C.:
E-mail: ronaldo.sierra@cecar.edu.co	Teléfono: +57 3004207462
E-mail:	Teléfono:
Programa: Ingeniería de Sistemas	
Línea de Investigación: Computación Aplicada	
Lugar de Ejecución del Proyecto: Sincelejo-Sucre	
Duración de Proyecto (en meses): 6 meses	

1. INTRODUCCIÓN

En Colombia cada año miles de estudiantes de 11° grado de todas las instituciones educativas se enfrentan a unas pruebas nacionales realizadas por el estado llamadas las pruebas Saber 11° Grado desarrolladas por la Instituto Colombiano para la Evaluación de la Educación (ICFES) que se realizan en dos fechas dos en el año, la primera fecha es a comienzos del mes de Abril con resultados en el mes de junio y la segunda fecha es a comienzos del mes de Agosto con resultados en el mes de octubre los resultados son con puntuación desde 0 a 500 puntos, de esta forma las pruebas son un requisito más para graduarse de bachiller académico, sin embargo esta prueba no es exclusiva para estos estudiantes personas que ya se hayan graduado como bachilleres pueden presentar las pruebas nuevamente para mejorar su puntaje obtenido.

Y es que dentro del marco legal los exámenes que realiza el icfes están sustentados dentro de la Ley 1324 de 2009, donde se establece que el objetivo del icfes es “Ofrecer el servicio de evaluación de la educación en todos sus niveles y adelantar la investigación sobre los factores que inciden en la calidad de la educación” (artículo 12°.). Por ello, estas pruebas tienen como propósito evaluar y medir la calidad de la educación ofrecida por las instituciones a los estudiantes de todo el país evaluando diferentes áreas importantes tales como Lectura crítica, Matemática, Ciencias naturales, Ciencias Políticas e Inglés. La importancia de estas pruebas no solo radica en el hecho de ser un requisito para graduarse como bachiller, si no con la obtención de un buen puntaje te permite aspirar a beneficios como becas o créditos condonables que te permitan estudiar en una institución de educación superior además de ser un requisito obligatorio para ingresar a una institución de educación superior, que le permita a los estudiantes cumplir sus metas de ser profesionales.

En este contexto en el colegio policarpa salavarrieta de la ciudad de Sincelejo, Sucre se pretende utilizar un modelo de predicción para pronosticar los resultados de los estudiantes de esta institución en el las pruebas saber 11 basándonos en los datos de sus históricos de notas, los modelos de predicción son algoritmos o técnicas de estadística que nos permite predecir comportamientos y resultados en base a datos históricos.

2. PROBLEMA DE INVESTIGACIÓN

2.1 Planteamiento del problema

Para el desarrollo de un modelo predictivo que permita a la institución pronosticar los resultados globales de las pruebas saber 11° en sus estudiantes, se cuenta con los datos del histórico de notas de todos los estudiantes desde sexto (6°) grado hasta décimo (10°) grado, y es que históricamente las instituciones educativas en Colombia han presentado dificultades para pronosticar el desempeño de sus estudiantes en las Saber 11°, esto debido a la falta de implementación de herramientas analíticas y modelos de aprendizaje, por ello utilizando la información de cada una de sus notas en todas las materias cursadas en los períodos dados y sus respectivos promedios estas herramientas de análisis nos permiten predecir esos puntajes de los estudiantes, lo que permitiría a las instituciones educativas poder realizar un análisis de cuáles serían las materias que presentan mayor dificultad a los estudiantes que son evaluadas dentro de las pruebas Saber 11°.

La institución educativa mantiene estos datos desde la matrícula de los estudiantes que empiezan desde sexto (6°) grado lo que equivale a 5 años hasta llegar a décimo (10°) y es que cuando los bachilleres académicos se gradúan se les entrega este historico de forma física o digital a cada uno de los estudiantes. Sin embargo, es importante recalcar que las Pruebas Saber 11° no evalúan la totalidad de las asignaturas que hacen parte del programa académico escolar. Por tanto es importante enfocar el análisis solamente en aquellas asignaturas que son evaluadas en dichas pruebas es esta forma identificar cuáles son las variables

dentro del historial académico tiene un mayor impacto en las competencias evaluadas.

Por ello, la implementación de esta herramienta en la institución educativa policarpa salavarrieta de la ciudad de Sincelejo, permite actuar de “alerta temprana” para mostrar un análisis de pronosticación, de esta manera permite a la institución tomar medidas pedagógicas que permitan mejorar esas brechas existentes en los estudiantes y así que estos tengan un desempeño mayor al pronóstico, de esta forma logrando un puntaje que permita los beneficios de las pruebas Saber 11°

2.2 Formulación del Problema

¿Cómo desarrollar e implementar un modelo predictivo que pronostique los resultados de los estudiantes de la institución educativa Policarpa Salavarrieta en las pruebas saber Icfes 11° utilizando técnicas de machine learning a partir de sus histórico de notas desde 6° a 10° grado?.

2.3 Justificación

Las pruebas saber 11 desarrolladas por el ICFES tienen una gran importancia no solo para los estudiantes y la institución educativa que los representa, si no también para el gobierno nacional de Colombia ya que estas pruebas funcionan como medidor de la calidad de la educación en Colombia por lo que buenos puntajes representan una mejora dentro del sistema educativo del país. Para los estudiantes es una oportunidad que le permita seguir sus estudios en una institución de educación superior mediante los beneficios que tienen estas pruebas para los estudiantes con excelentes puntajes. Además, que los estudiantes obtengan un buen desempeño también le permite a las instituciones educativas hacer una medición de la calidad pedagógica hacia los estudiantes, de esta manera generando un prestigio para la institución dentro de la sociedad académica. Por ello se entiende la importancia de estas pruebas para los estudiantes por lo que un modelo que pronostique cuales serían esos puntajes

podría permitirle a los estudiantes y profesores hacer un énfasis en cuáles serían esos puntos débiles de los estudiantes y poder permitirles mejorar en esos aspectos débiles y lograr que una buena cantidad de estudiantes logren obtener un excelente rendimiento en las pruebas saber 11°.

Por ello, La implementación de un modelo de predicción permite a la institución implementar una solución temprana que permita evaluar todas brechas existentes con los conocimientos y es que en la actualidad existen innumerables cursos de preparación para los estudiantes para las pruebas saber 11, donde se concentra en desarrollar las habilidades para responder de formas más ágiles, pues las pruebas tienen un tiempo para ser desarrolladas, sin embargo, esto sólo son correcciones superficiales y genera una brecha entre todos los conocimientos acumulados durante los 5 años de estudio. La institución posee un recurso importante como el histórico de notas de los estudiantes desde 6° a 10° por ello este proyecto permite transformar toda esta información estática que permitirá predecir el rendimiento de los estudiantes en las pruebas saber 11°.

3. OBJETIVOS

3.1 Objetivo General

Desarrollar e implementar un modelo de predicción del desempeño de los estudiantes en las pruebas saber 11° del colegio policarpa salavarrieta a partir del histórico de notas utilizando técnicas de machine learning

3.2 Objetivos Específicos

- Analizar el comportamiento histórico de los registros académicos de los estudiantes mediante técnicas de análisis estadístico y exploratorio de datos (EDA), con el propósito de identificar las variables predictoras más relevantes que inciden en el desempeño en las pruebas Saber 11°.
- Procesar el conjunto de datos mediante técnicas de limpieza, normalización, codificación de variables categóricas y tratamiento de valores atípicos, con el fin de establecer una base de datos estructurada y consistente para el entrenamiento de los modelos predictivos.

- Aplicar técnicas de aprendizaje automático para determinar el modelo con mayor precisión, capacidad de generalización y eficiencia computacional en la predicción del desempeño académico de los estudiantes.

4. ESTADO DEL ARTE

Yamile Peña Lozano & José Jhon Fredy González Veloza.(2022). En su artículo científico llamado Modelo de predicción de los resultados de la prueba icfes saber 11 en el área de matemáticas a partir de variables socioeconómicas. Donde buscan generar un modelo de predicción de los resultados a partir de condiciones socioeconómicas de los estudiantes que llevaron a cabo este examen. Para la metodología se utilizó la base de datos del icfes de los estudiantes que presentaron la prueba en 2020 analizando las variables de género, estrato, número de personas que conforman el hogar, educación de la madre, acceso a internet, disponibilidad de computadora en el hogar, horas de trabajo semanal del estudiante, naturaleza de la Institución Educativa, área de ubicación geográfica de la Institución Educativa y el puntaje obtenido en la prueba de matemáticas. Estas pruebas se realizaron mediante técnicas de Machine Learning y el modelo LightGBM utilizando también el paquete PyCaret de Python.

Pérez, A. M. A., & Altamiranda, J. C. B. (2020) . En su artículo llamado Análisis del impacto del modelo de excelencia EFQM en el desempeño de los colegios en la prueba saber 11 mediante técnicas de minería de datos abarca el estudio realizado en los resultados de las pruebas icfes saber 11 presentada por aquellos estudiantes que aspiran a terminar sus estudios de secundaria en los colegios de Colombia entre los periodos 2016-1 a 2018-2. Para esta investigación utilizaron técnicas de minería de datos y utilizando la aplicación RStudio para el respectivo análisis, estos estudios fueron realizados con el objetivo de describir el impacto que tienen los certificados de calidad, otorgados en el país por distintas entidades acreditadoras donde se plantea que estas certificaciones tienen un impacto positivo en las pruebas saber 11 ayudando a los colegios acreditados a obtener

mejores puntajes frente a los colegios no acreditados.

Echeverri Guluma, D. F., Quiroga Amado, D. V., & Villarraga Gallo, K. J. (2024). En su informe de investigación llamado Los resultados del ICFES: un reflejo de la realidad educativa en el departamento del Meta realizan un enfoque en los resultados de las pruebas saber 11 en el departamento del Meta. Donde el objetivo principal fue evaluar la efectividad del sistema educativo a través del análisis de esos resultados. De esta manera identificando tendencias y formulación de recomendaciones para la mejora de los resultados en las pruebas de los estudiantes hacia la educación superior. Para llevar a cabo este proyecto se utilizaron datos de 50 instituciones educativas. En la metodología se aplicaron técnicas de estadística avanzada para analizar las variables externas y de los resultados obtenidos, donde también se utilizaron herramientas como RStudio para el tratamiento y visualización de datos. Donde se llegó a la conclusión de que se debe mejorar la calidad de estudio en las instituciones del departamento del Meta.

Garcia Cano, M. A. (2024) Plantean en su estudio Técnicas de machine learning para la predicción del rendimiento académico en las pruebas saber pro en Colombia incluyendo regresión lineal, regresión logística y árbol de decisión para prever el rendimiento académico de los estudiantes de pregrado en las pruebas Saber Pro periodo 2022. El objetivo de este informe crear un modelo de predicción pero para poder llegar a una buena predicción deciden evaluar cada una de estas técnicas de machine learning ya mencionadas para determinar cual es más precisa a la hora de realizar pronosticar el rendimiento académico de los estudiantes en las pruebas saber pro, esto permite identificar las falencias de los estudiantes para que las instituciones de educación superior desarrollen programas personalizados para mejorar esos aspectos.

Timaran Pereira, R. Caicedo Zambrano, J. Hidalgo Troya, A. (2019) En su documento Árboles de decisión para predecir factores asociados al desempeño

académico de estudiantes de bachillerato en las pruebas saber 11° donde el artículo presenta los resultados que obtuvieron aplicando un modelo de clasificación basado en árboles de decisiones para detectar los factores asociados al desempeño académico de los estudiantes Colombianos de grado undécimo de educación media, que presentaron las pruebas saber 11° entre los años 2015 - 2016. Esta investigación fue de tipo descriptiva pero con un enfoque cuantitativo, aplicando un diseño no experimental. Donde siguiendo la metodología CRISP-DM se seleccionó la base de datos del Icfes de los estudiantes. Luego, se construyó, limpio y transformó un repositorio de datos utilizando técnicas de minería de datos con la herramienta WEKA. De esta forma permitió generar árboles de decisiones que permitieron identificar patrones asociados al buen o mal desempeño de los estudiantes en las pruebas saber 11°

Clavijo, M. A. V., Zapata, L.K., Correa, M., & Toro, M. En su artículo PREDICCIÓN DE RESULTADOS EN LAS PRUEBAS SABER PRO A PARTIR DE LAS PRUEBAS SABER 11. Menciona que en busca de construir con las predicciones en el éxito de la educación superior colombiana, plantearon generar un algoritmo basado en bloques aleatorios de árboles de decisiones que permita observar diversos factores que influyen en el proceso de los estudiantes para poner a prueba sus conocimientos en las pruebas. En este estudio se pretende utilizar una metodología diferente, es decir, no utilizando análisis estadístico si no, utilizando árboles de decisiones lo que permite abarcar más variables que permitan obtener mejores resultados en las predicciones.

Cardozo Anaya, J. M. (2023) Modelo de regresión para predecir el puntaje esperado en la Saber 11° para los estudiantes del colegio Cajasai en su informe explica la creación de un modelo de regresión para establecer a futuro un puntaje en las pruebas saber 11° para los estudiantes de la isla de San Andrés pertenecientes al Colegio Cajasai. Correspondiente a los resultados de los

simulacros realizados durante el año 2022 y pruebas Saber 11° realizadas el mismo año, de esta manera se adiestraron diversos modelos de regresión utilizando aprendizajes automatizados supervisados para predecir el puntaje de los estudiantes de San Andrés. Donde se encontró que el modelo de regresión con mayor rendimiento en los datos de testeo fue el Huber en con su RSME de 26.2683. Con los resultados que obtuvieron pueden determinar el puntaje que pueden obtener los estudiantes en la prueba Saber 11°.

Serna, Hernandez y Orozco (2021). En su artículo La characterization of high school students in the department of Risaralda using the Chi-Square metric implementan una metodología para predecir los resultados de las pruebas ICFES saber 11° que permita subsanar la problemática educacional que viene presentando Colombia en la educación media. Para el desarrollo de esta metodología se utilizó como base los datos del Saber 11° del ICFES, donde se realizó su preprocesamiento dentro del software Matlab. Además, de pruebas combinadas con la nueva métrica de Chi-Square que fue desarrollada por los investigadores del grupo de automática de la Universidad tecnológica de Pereira, obteniendo los resultados superiores al 20% comparado con las técnicas convencionales de clasificación.

Neita-Sanchez, A.G. & Mora-Giraldo, J.D (2022). En su trabajo de grado llamado Uso de machine learning para la predicción de resultados de las pruebas saber 11 en el instituto San Ricardo Pampuri. Donde esta investigación tomó como insumo los resultados de las últimas pruebas saber 11 que fueron realizadas desde el año 2010 hasta 2021 por los estudiantes de la institución no oficial Instituto San Ricardo Pampurí, con la extracción de los datos se utilizaron las técnicas de modelo de regresión lineal múltiple y modelo de árbol de regresión con el fin de desarrollar el modelo para predecir el resultado global del año 2023. Para la construcción del modelo se realizó en seis fases teniendo como resultado el modelo de árbol de regresión lineal como el más apto en rendimiento en

	PROPUESTA DE TRABAJO GRADO	FCBIA FO-TG-001
---	---------------------------------------	--------------------

comparación con el modelo de regresión lineal múltiple.

5. METODOLOGÍA

Para el desarrollo de este modelo predictivo del desempeño de los estudiantes de la Institución Educativa Policarpa Salavarrieta en las pruebas Saber 11° se pretende adoptar la metodología ASUM-DM una evolución de la metodología CRISP-DM creada por IBM que están orientadas a proyectos modernos de analítica avanzada, a aprendizaje automático, minería de datos y ciencia de datos. La estructura flexible de esta metodología permite llevar un orden iterativo dentro de cada fase lo que permite integrar todos los procesos de comprensión del negocio, análisis de requerimientos, construcción de modelos y despliegue de soluciones, de esta forma la hace bastante adecuada para proyectos basados en datos longitudinales.

La elección de esta metodología corresponde a la necesidad de contar con un marco metodológico robusto que permita gestionar eficazmente todas las fases del proyecto analítico y garantizar una solución sistemática, reproducible y alienada tanto a las necesidades institucionales como los estándares en ciencia de datos.

El proceso metodológico se encuentra estructurado en seis (6) fases. Cada fase permite llevar un orden y analizar cada requerimiento que sea necesario lo que permite ser un proceso iterativo lo que reduce el porcentaje de errores. De esta forma desde la fase 1 donde se obtienen los datos hasta la fase 6 de despliegue se mantiene un enfoque riguroso y de alta calidad. Con esta estructura se garantiza un sistema robusto, moderno, estructurado y alineado a los objetivos del estudio.




Figura 1.0 Analytics Solutions Unified Method (ASUM).

Fuente: IBM Corporation

6. CRONOGRAMA

Fases	Actividades	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Fase 1 - Inicio Del Proyecto	Definición del problema de predicción del desempeño académico						
	Revisión del histórico de						

	notas disponibles						
Fase 2- Entender los datos	Recolección de los datos (dataset)						
	Verificación de estructura, tipos de datos y diccionario						
	Análisis exploratorio EDA						
	Análisis de calidad de datos						
Fase 3 - Preparar Los Datos	Transformación, limpieza de datos (eliminación de valores nulos, etc.)						
	Normalización y estandarización de variables numéricas						
	División del dataset de entrenamiento, validación y pruebas						

Fase 4 - Construir el modelo	Selección de modelos						
	Entrenamientos con varios algoritmos						
	Evaluación preliminar del desempeño						
Fase 5 - Evaluar el modelo	Validación profunda del modelo seleccionado						
	Análisis del comportamiento de variables						
	Pruebas de estabilidad y generalización						
Fase 6 - Despliegue	Implementación del modelo en entorno local						
	Documentación técnica y académica del proyecto						
	Creación de dashboard						

REFERENCIAS BIBLIOGRÁFICAS

República de Colombia. (2009). Ley 1324 de 2009: Por la cual se fijan parámetros y criterios para organizar el sistema de evaluación de resultados de la calidad de la educación, se dictan normas para el fomento de una cultura de la evaluación, en procura de facilitar la inspección y vigilancia del estado y se transforma el Icfes. Diario Oficial No. 47.409.

Lozano, Y. P., & Veloza, J. J. F. G. (2022). Modelo de predicción de los resultados de la prueba icfes saber 11 en el área de matemáticas a partir de variables socioeconómicas: Modelo de previsão de resultados de testes icfes saber 11 na área de matemática baseado em variáveis socioeconómicas. *Studies in Engineering and Exact Sciences*, 3(1), 52-68.

IBM Corporation. (2016). *ASUM-DM: Analytics Solutions Unified Method for Data Mining*. IBM Redbooks.

<https://www.redbooks.ibm.com/redpapers/pdfs/redp4885.pdf>

IBM Corporation. (2016). *Analytics Solutions Unified Method (ASUM). Datasheet*. Recuperado de <https://public.dhe.ibm.com/software/data/sw-library/services/ASUM.pdf>

Wirth, R., & Hipp, J. (2000). *CRISP-DM: Towards a standard process model for data mining*. Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining, 29–39.

Pérez, A. M. A., & Altamiranda, J. C. B. (2020). ANÁLISIS DEL IMPACTO DEL MODELO DE EXCELENCIA EFQM EN EL DESEMPEÑO DE LOS COLEGIOS EN LA PRUEBA ICFES SABER 11 MEDIANTE TÉCNICAS DE MINERÍA DE DATOS.

Echeverri Guluma, D. F., Quiroga Amado, D. V., & Villarraga Gallo, K. J. (2024). Los resultados del ICFES: un reflejo de la realidad educativa en el departamento del Meta.

Garcia Cano, M. A. (2024) Técnicas de machine learning para la predicción del rendimiento académico en las pruebas saber pro en Colombia.

Timarán-Pereira, R., Caicedo-Zambrano, J., & Hidalgo-Troya, A. (2019). Árboles de decisión para predecir factores asociados al desempeño académico de estudiantes de bachillerato en las pruebas Saber 11. *Revista de investigación, desarrollo e innovación*, 9(2), 363-378.

Clavijo, M. A. V., Zapata, L. K., Correa, M., & Toro, M. PREDICCIÓN DE RESULTADOS EN LAS PRUEBAS SABER PRO A PARTIR DE LAS PRUEBAS SABER 11.

Cardozo Anaya, J. M. (2023). Modelo de regresión para predecir el puntaje esperado en la Saber 11 para los estudiantes del colegio Cajasai.

Serna Cardona, L. A., Hernández Gómez, K. A., & Orozco Gutiérrez, Álvaro Ángel. (2021). the Characterization of high school students in the department of Risaralda using the Chi-Square metric: Caracterización de los estudiantes de educación media en el departamento de Risaralda usando la métrica Chi-Square. *Scientia Et Technica*, 26(2), 119–126. <https://doi.org/10.22517/23447214.24587>

Neita-Sánchez, A. G. & Mora-Giraldo, J. D. (2022). Uso de machine learning para la predicción de resultados de las pruebas saber 11 en el Instituto San Ricardo Pampurí. Trabajo de Grado. Universidad Católica de Colombia. Facultad de Ingeniería. Programa de Ingeniería de Sistemas. Bogotá, Colombia.